


醫美診所 LINE AI 客服 — 系統架構說明


本文件描述 `line_clinics_agent` 專案的整體架構：從後端串接 (`/chat` API) 進入請求，經過 OCR 圖片預處理、LangGraph 多代理協作 (Supervisor → Information / Booking → Moderator)，到最後以「文字 + 圖片清單」回傳的完整流程。

1. 高層流程概觀



2. 系統架構圖 (Mermaid)





3. 對外 API 介面 (`main_webhook.py`)

Method	Path	說明
POST	/chat	後端工程師串接用的主要端點，回傳文字 + 圖片清單

Request (`BackendUserQuery` — `app/models.py`)

```
{
  "line_uuid": "U1234567890abcdef...",
  "messages": [
    { "role": "user", "content": "我最近痘痘變多", "image_url": "https://..." },
    { "role": "assistant", "content": "..." },
    { "role": "user", "content": "有哪些選擇?" }
  ]
}
```

Response (`BackendResponse`)

```
{
  "text": "AI 回覆的純文字 (已移除圖片 URL) ",
  "images": ["https://.../neo_intro.jpg", "https://.../parking_lots.jpg"]
}
```

`line_uuid` 同時被當作 LangGraph checkpoint 的 `thread_id`，因此同一個使用者的對話會在 `checkpoints.sqlite` 中累積延續。

4. 預處理層 — 圖片 OCR

實作於 `backend_agent_service.ocr_image_with_llm()`:

- 用獨立 `ChatOpenAI(model="gpt-4o-mini", temperature=0)` 實例。
- 刻意不掛醫美 **system prompt**，prompt 只要求「輸出圖片中的所有文字」，目的是避開 OpenAI 對醫療類圖片的 **Safety Filter**。
- OCR 結果會以 `\n\n[客人上傳的圖片內容: ]\n{...}` 形式附加在使用者原文後面，再丟進主 Agent。

5. 多代理工作流 (`agent.py`)

5.1 State 結構 (`AgentState`)

```
class AgentState(TypedDict):
    messages: Annotated[list[Any], add_messages]
    phone_number: str          # 實際存放 line_uuid
    next: str
    query: str
    current_reasoning: str
    booking_completed: bool
    should_terminate: bool
```

5.2 節點清單

節點	角色
start_profile	初始化節點：注入 phone_number (= line_uuid)，導向 supervisor。
supervisor_node	「醫美診所經理」，用 with_structured_output(Router) 決定下一步。
information_node	ReAct agent，處理症狀理解、同理回應與療程介紹。
booking_node	ReAct agent，處理預約、費用、地址、電話等診所資訊。
moderator_node	法規 / 語氣 / 錯字審查，最後一道把關。

5.3 Graph 連線

```
START → start_profile → supervisor
      |
      ├── information_node → moderator_node → END
      ├── booking_node     → moderator_node → END
      └── FINISH (AIMessage: 「感謝您的諮詢...」) → END
```

5.4 持久化

使用 `SqliteSaver (checkpoints.sqlite)`，並以 `check_same_thread=False` 讓 FastAPI 多執行緒下安全共用。

6. Supervisor 路由規則

supervisor_node 用一段中文 system prompt + `with_structured_output(Router)` 強制輸出：

```
class Router(TypedDict):
    next: Literal["information_node", "booking_node", "FINISH"]
    reasoning: str
```

判斷原則摘要：

條件	路由
描述症狀 / 詢問療程原理 / 改善方向（皮膚、體態、私密、睡眠神經）	information_node
包含「費用 / 價錢 / 初診 / 地址 / 電話 / 預約 / 改期 / 取消 / 時間」	booking_node
「謝謝 / 沒事 / 沒問題了」等結束語	FINISH
與醫美無關（政治、法律、技術等）	禮貌拒絕並導回醫美

7. Information Node

- 模式：create_react_agent (Thought → Action → Observation 循環，但不輸出過程)。
- 工具：
 - get_empathy_questions_by_symptom(symptom_tag)：以標準標籤（皺紋類 / 私密療程 / 睡眠與神經 / 體態管理 / 皮膚其他）查內建字典，回傳同理話 + 1 個追問。
 - search_clinics_by_keyword(symptom)：呼叫 ensemble_retriever 從 data/clinics_introductions3.csv 找療程介紹。
- 關鍵 Prompt 規則：
 - 一回合最多呼叫一個工具。
 - 症狀必須先歸一化為標準標籤，再傳給同理工具。
 - 嚴禁循環追問；客人若已給 ≥2 個關鍵字就直接給專業建議。
 - 不可主動誇大療效；提到療程時用「可以幫助改善 / 有些人會選擇」這類保守語氣。
 - 想出對比照時，需用固定格式：「這是[療程名稱]的對比照：<https URL>」，下游才能正確抽圖。

8. Booking Node

- 模式：create_react_agent。
- 工具：
 - set_appointment(symptom)：回傳一段制式預約資訊收集表單（姓名 / 療程 / 時間 / 特殊需求 / 電話），並把 should_terminate=True。
 - search_clinics_info(treatment_name, category="費用")：呼叫 qa_retriever 在 data/clinics_qa.csv 中以「療程名稱 ×3 + 類別」做 boosted query 後回傳第一筆 QA。
- 關鍵 Prompt 規則：
 - 預約 → set_appointment；診所資訊 → search_clinics_info。兩者不可同時呼叫。
 - 客人問「費用」但沒指定療程：先回看上文是否提過療程，有則確認；沒有再反問。
 - 嚴禁套用 prompt 範例（如腦波機 / 紅光）反問使用者。

9. Moderator Node — 出口審查

每次 information_node 或 booking_node 的回覆都會經過 moderator_node：

1. **錯字修正**：例如 NEOT → NEO；但嚴禁把「猛健樂 / 瘦瘦筆 / 週纖達」自動改成 EMBODY。
2. **法規 / 語氣**：移除誇大、保證性字眼（「即時效果」「一定會好」「完全消除」「治癒」）。
3. **語言一致性**：強制繁體中文，僅特定療程名（NEO, EMBODY）保留英文，其他 fat/muscle 等翻成中文。
4. 直接回傳純文字給使用者，不能加任何「這是修改後版本」之類的前言。

10. 後處理 — 動態圖片決策

回覆從 LangGraph 出來後, `backend_agent_service.execute_backend_agent` 會做:

1. `extract_image_urls(text)` — 用 regex 撈出 `https://*. {jpg, jpeg, png, webp}`。
2. `determine_additional_images(ai_reply, user_query, extracted_urls)` 依以下優先順序補圖:

條件	補的圖
回覆包含「兩種方案」或「自律神經檢測」	<code>treatment_procedure.jpg</code> + <code>autonomic_fees.jpg</code>
回覆談「地址 / 地點 / 位於」或使用者問「哪裡 / 停車 / 開車」	<code>parking_lots.jpg</code>
否則: 偵測 <code>Emface</code> / <code>NEO</code> / <code>SIS</code> / 瘦瘦筆 / 週纖達 / <code>EMBODY</code> / 體態檢測 / 冷凍 / 冷脈衝	呼叫 <code>clinics_image_embedding_api</code> (score $\geq$ 0.7) 取對應療程圖

特殊規則:

- 冷凍 → 冷脈衝、瘦瘦筆 → 週纖達 在搜圖前先正規化。
- **Emface 過濾**: 若回覆已含圖 URL 或提到「電波」, 跳過補圖。
- **互斥療程清單** (`NEO` / `SIS` / 週纖達 / `EMBODY` / 冷脈衝): 同一回覆出現 2 個以上時, 全都不補介紹圖 (避免一次塞太多療程圖)。

3. `clean_text_from_urls(text, urls)` — 把抽出的圖片 URL 從正文中拿掉。
4. **停車補丁**: 當最終 images 含 `parking_lots.jpg` 但正文沒提到「春光公園」, 會強制覆蓋為一句固定的停車說明。

11. Retrievers

兩支 Retriever 都是 **Vector + BM25 的 EnsembleRetriever**, 共用 `utils/shared_resources.py` 的 embedding model 與中文 jieba tokenizer。

11.1 ensemble_retriever — 療程介紹 (給 information_node)

- 來源: `data/clinics_introductions3.csv` (big5)。
- 兩份文件視角:
 - vector: 原文。
 - keyword: 把 `suitable_for` 重複 3 次以加強 BM25 對「適合對象」的命中。
- 持久化: Chroma → `./chroma_token_split`, BM25 → `./bm25.pkl`。
- 權重: `vector 0.3` / `keyword 0.7`, `k = 5` (vector) / 3 (BM25)。

11.2 qa_retriever — 診所 QA (給 booking_node)

- 來源: `data/clinics_qa.csv` (utf-8-sig)。
- keyword 文件把 `keywords` 欄重複 3 次。

- 持久化: Chroma → ./chroma_qa, BM25 → ./bm25_qa.pkl。
- 權重: `vector 0.7 / keyword 0.3`, `k = 2 / 2`。
- 工具呼叫端 `search_clinics_info` 還會再做 query boosting: `"{name} {name} {name} {category}"`。

12. 模型與外部依賴

用途	模型 / 服務
主 LLM (<code>utils/llms.py</code>)	<code>ChatOpenAI("gpt-4o-mini")</code>
OCR	<code>ChatOpenAI("gpt-4o-mini", temperature=0)</code> 獨立實例
Embedding	<code>utils/shared_resources.embedding_model</code>
圖片檢索 API	<code>https://ai.gastom.com.tw/clinics_image_embedding_api/api/search</code> (POST)
對話持久化	SQLite (<code>checkpoints.sqlite</code>) via <code>langgraph.checkpoint.sqlite.SqliteSaver</code>
使用者 Profile (備用)	MySQL, <code>utils/profile_db.get_user_profile_by_uuid</code>

13. 重要目錄結構

```
line_clinics_agent/  
├─ main_webhook.py           # FastAPI entrypoint (/chat)  
├─ agent.py                  # LangGraph 多代理 (Supervisor / Info / Booking /  
Moderator)  
├─ app/  
│   ├── backend_agent_service.py # OCR + 動態圖片 + Agent 包裝  
│   └─ models.py                # BackendUserQuery / BackendResponse  
├─ toolkit/  
│   └─ toolkits.py              # set_appointment / search_clinics_by_keyword /  
search_clinics_info / get_empathy_questions_by_symptom  
├─ utils/  
│   ├── llms.py                # LLMModel (gpt-4o-mini)  
│   ├── ensemble_retriever.py   # 療程介紹 (vector+BM25)  
│   ├── qa_retriever.py         # 診所 QA (vector+BM25)  
│   ├── shared_resources.py     # embedding model + 中文 tokenizer  
│   └─ profile_db.py           # MySQL 使用者資料 (備用)  
├─ prompt_library/prompt.py    # 早期 supervisor system prompt (現已內嵌於  
agent.py)  
├─ data/  
│   ├── clinics_introductions3.csv  
│   └─ clinics_qa.csv  
├─ chroma_token_split/         # 療程介紹 vector store  
└─ chroma_qa/                  # QA vector store
```

```
└─ bm25.pkl / bm25_qa.pkl      # BM25 retriever 快取
└─ checkpoints.sqlite          # LangGraph 對話狀態
```

14. 一次完整請求的時序

```
Backend → POST /chat (line_uuid, messages[, image_url])
      |
      ▼
backend_agent_service.execute_backend_agent
  1. for each user msg with image_url: ocr_image_with_llm() (gpt-4o-mini, no
  medical prompt)
  2. 文字 + OCR 結果 → HumanMessage(content=[{type:"text", text:...}])
  3. agent.workflow().invoke(query_data, config={thread_id: line_uuid,
  recursion_limit: 20})
      |
      ▼
  LangGraph
    start_profile → supervisor
    Router(next, reasoning)
      └─ information_node (ReAct: empathy / search_clinics_by_keyword)
      └─ booking_node    (ReAct: set_appointment / search_clinics_info)
      └─ FINISH (固定收尾語)
      → moderator_node (法規 + 錯字 + 中文化)
      → END
      |
      ▼
  4. extract_image_urls(text)
  5. determine_additional_images(...) → 視內容呼叫 image embedding API
  6. clean_text_from_urls(...)       → 文字去 URL
  7. 停車場資訊強制補字
      |
      ▼
BackendResponse(text, images) → Backend
```

15. 設計上的幾個關鍵決定

1. **OCR 與主 Agent 解耦**：避開 OpenAI 對醫療影像的 Safety Filter，OCR 用無領域 prompt 的乾淨模型實例。
2. **意圖路由用 structured output**：Router TypedDict 強制 LLM 只能回 `information_node` / `booking_node` / `FINISH`，不會出現自由發揮。
3. **Moderator 作為最後一道關**：所有對外文字都經過合規/語氣審查，把醫藥法規風險集中處理在單點。
4. **圖片不交給 LLM 自由生成**：療程圖以「關鍵字判斷 + 對外 embedding API」決定，避免 LLM 幻覺出不存在的 URL；對比照才允許在 prompt 裡用固定格式內嵌。
5. **Vector + BM25 雙路檢索**：療程介紹偏 BM25（命中具體療程名/適合對象），QA 偏 vector（語意相近的問法），權重分別調校。
6. **以 line_uuid 作 thread_id**：天然以使用者為單位做對話持久化，不需另外維護 session。